Projet Data Science en nutrition humaine

Objectif pédagogique : mener un projet de Data Science de bout en bout, de la question scientifique à la restitution des résultats, et savoir le présenter de façon claire et argumentée, à l'écrit comme à l'oral, par exemple lors d'un entretien pour un poste de Data Scientist en sciences de la vie.

Les étapes d'un tel projet sont les suivantes :

1. Formuler le problème scientifique dans un langage clair et facilement compréhensible. Donner des exemples de questions auxquelles ce projet peut répondre.
2. Identifier les données disponibles.
    a. Évaluer leur volumétrie et leur qualité.
    b. Établir pour chaque jeu de données une fiche d'identification.
    c. Choisir les jeux de données qui seront utilisés pour le projet.
3. Data engineering :
    a. Charger, nettoyer, explorer et visualiser les données ; les organiser dans un modèle relationnel
    b. Gestion des valeurs manquantes
    c. Représentativité de l'échantillon et pondérations d'enquête
    d. Confidentialité (RGPD, données pseudonymisées)
    e. Biais de sélection et de déclaration (par exemple sous-déclaration des apports)
4. Proposer des indicateurs ainsi que les méthodes statistiques ou d'apprentissage automatique (ML) permettant de répondre aux questions identifiées à la première étape.
5. Présenter les résultats et leur interprétation.
6. Donner des arguments pour justifier
    a. Le choix des métriques
    b. La validation des méthodes choisies et la robustesse des résultats
    c. La reproductibilité du pipeline
    d. La traçabilité des données

Dans la suite de ce document, ces étapes sont illustrées sur un projet de nutrition humaine, NutriHFr, à réaliser pour l'évaluation du module.

Cadre du projet

- **Organisation :** travail individuel ou en binôme.
- **Calendrier :** jalons intermédiaires conseillés :
    - (1) choix des données et fiches d'identification ;
    - (2) modèle relationnel et pipeline de nettoyage ;
    - (3) analyses et dashboard ;
    - (4) rendu final : le 23 octobre à 18h.

- **Outils :** Python (pandas, matplotlib/seaborn), SQL (SQLite ou PostgreSQL), Git, Streamlit ou Dash pour le dashboard.
- **Niveaux d'exigence :** socle (questions Q1 à Q6), attendu (pondérations, sous-déclaration, tests automatisés), bonus (questions « Pour aller plus loin »).
- **Évaluation :** livrables de l'annexe B, évalués selon les critères de l'annexe A.

---

1. Objectif

La première étape est de répondre à la question « Quel est le problème scientifique traité ? »

Pour l'exemple du projet de nutrition humaine, nommé NutriHFr, la question scientifique est la suivante : « **Comment se caractérisent les consommations alimentaires et les apports nutritionnels de la population française, comment varient-ils selon l'âge et le sexe, et quels aliments y contribuent le plus ? »**

Cette analyse permettra de répondre, par exemple, aux questions suivantes :

- Quels sont les apports énergétiques moyens ?
- Comment varient-ils selon l'âge et le sexe ?
- Quels aliments contribuent le plus aux apports en protéines, calcium, fer, fibres, etc. ?
- Quelle est la variabilité interindividuelle ?
- Existe-t-il différents profils alimentaires ?
- Comment comparer plusieurs enquêtes alimentaires ?

---

2. Les données

La deuxième étape est d'identifier les données disponibles pour répondre à l'objectif du projet NutriHFr.

Pour les enquêtes individuelles de consommation alimentaire, il existe en France plusieurs sources :

- INCA 1 (1998-1999)
- INCA 2 (2006-2007)
- INCA 3 (2014-2015)
- NutriNet-Santé (cohorte en ligne lancée en 2009 ; données non ouvertes, accès sur demande)

Par exemple, INCA 3 (https://www.data.gouv.fr/datasets/donnees-de-consommations-et-habitudes-alimentaires-de-letude-inca-3) correspond à l'étude individuelle nationale des consommations alimentaires menée en 2014-2015. Ce jeu de données comprend également des apports nutritionnels calculés par individu : les recalculer à partir des consommations et de Ciqual, puis les comparer aux valeurs fournies, constitue un bon test de validation du pipeline.

Pour la composition nutritionnelle des aliments, on peut citer :

- Ciqual (table de composition nutritionnelle de référence de l'Anses, aliments génériques)
- Open Food Facts (base collaborative de produits de marque)

Attention aux versions : la table de composition utilisée pour INCA 3 n'est pas la version la plus récente de Ciqual. La version retenue doit être documentée et justifiée.

Avant de choisir les jeux de données qui seront utilisés pour le projet NutriHFr, il faut :

a. Évaluer leur volumétrie et leur qualité.
b. Établir pour chaque jeu de données une fiche d'identification.

Pour aller plus loin (niveau bonus), on pourra chercher des sources de données complémentaires, par exemple :

- classification des aliments ; groupes alimentaires ; régimes
- données socio-démographiques ;
- tables de conversion unités/poids ;
- éventuellement données sur les portions alimentaires.

---

3. Data Engineering

L'objectif de cette étape est de charger, nettoyer, explorer et visualiser les données, puis de les organiser dans un modèle relationnel adapté aux questions de la section 4.

Concrètement, il est demandé de concevoir ce modèle (tables, clés primaires et étrangères), par exemple avec les tables suivantes : individus, journées de consommation, consommations, aliments, composition, nutriments, puis de l'implémenter en SQL. Le pipeline sera structuré en classes Python (chargement, contrôle qualité, calcul des apports).

---

4. Méthodes

Pour chacune des questions suivantes, préciser l'indicateur, la méthode et la visualisation retenus (voir le tableau ci-dessous) :

- **Q1 — Apports énergétiques :** Quelle est la distribution de l'apport énergétique journalier ?
- **Q2 — Sexe :** Comment les apports nutritionnels diffèrent-ils selon le sexe ?
- **Q3 — Âge :** Comment évoluent les apports nutritionnels avec l'âge ?
- **Q4 — Densité nutritionnelle :** Comment comparer les apports nutritionnels à énergie comparable ?

- **Q5 — Contributeurs :** Quels sont les principaux aliments contribuant aux apports en protéines ?
    - Répéter l'analyse pour :
        - calcium ;
        - fer ;
        - fibres ;
        - vitamine C ;
- **Q6 — Variabilité :** Quelle est la variabilité interindividuelle des apports au sein d'un même groupe (par exemple chez les femmes 25 - 44 ans) ?

Le tableau suivant propose, pour chaque question, des indicateurs et des méthodes possibles :

Question	Indicateur	Méthode	Visualisation
Q1 Énergie	apport énergétique (kcal/j) par individu	statistiques descriptives pondérées, IC 95 %	histogramme, densité
Q2–Q3 Sexe et âge	apports par sexe et classe d'âge	comparaisons pondérées, régression	boxplots par classe
Q4 Densité	apport pour 1000 kcal	rapport nutriment / énergie	diagramme en barres
Q5 Contributeurs	% de contribution de chaque groupe d'aliments	ratio des moyennes (à justifier face à la moyenne des ratios)	barres empilées
Q6 Variabilité	moyenne, médiane, quartiles, P5/P95	percentiles pondérés	violin plot
Profils (bonus)	consommations par groupe d'aliments	ACP puis classification (k-means ou CAH)	biplot, projection des clusters
Mapping (bonus)	taux de correspondance	appariement approximatif de chaînes ou embeddings, évalué par précision et rappel	matrice de confusion

Points méthodologiques propres aux enquêtes de nutrition, à traiter :

- **Pondérations d'enquête :** INCA 3 fournit des poids d'échantillonnage ; les moyennes et les percentiles doivent être pondérés ;
- **Sous-déclaration :** identifier les sous-déclarants de l'apport énergétique, par exemple avec le critère de Goldberg (rapport apport énergétique / métabolisme de base), et mesurer l'effet de leur exclusion ;
- **Apport d'un jour et apport habituel :** distinguer la variabilité intra-individuelle (d'un jour à l'autre) de la variabilité interindividuelle (Q6).

Pour aller plus loin (niveau bonus) :

- **Q_Profils alimentaires :** Existe-t-il des profils alimentaires distincts (par exemple riche en produits sucrés, riche en produits végétaux) ?
- **Q_Divers :** Les personnes ayant une consommation énergétique élevée ont-elles également une alimentation plus diversifiée ?

- **Q_Comp_Conso :** Comment comparer entre elles les enquêtes de consommation, compte tenu des différences de :
    - population ;
    - périodes d'enquête ;
    - nomenclatures ;
    - méthodes de collecte ;
    - groupes d'âge ;
    - définition des aliments
- **Q_Evolution_Temporelle** : Comment les habitudes alimentaires ont-elles évolué entre INCA 1, INCA 2 et INCA 3 (par exemple consommation de fruits, légumes, poisson) ?
- **Q_Mapping_INCA_CIQUAL** : Comment automatiser le mapping entre les aliments de l'enquête et les aliments de Ciqual ?

---

5. Résultats

Pour chaque question, présenter les tableaux et les figures obtenus, accompagnés d'une interprétation en langage clair (que faut-il retenir ?), en précisant les effectifs, la pondération utilisée et les intervalles de confiance.

---

6. Discussion

Donner des arguments pour justifier

1. Le choix des métriques
2. La validation des méthodes choisies et la robustesse des résultats (analyses de sensibilité : avec ou sans sous-déclarants, pondéré ou non)
3. La reproductibilité du pipeline
4. La traçabilité des données
5. Les limites de l'étude (méthode de recueil, sous-déclaration, nomenclatures, versions de Ciqual, couverture du mapping).

Annexe A. Critères de réussite

Voici des critères de réussite pour un projet Data Science et en particulier pour le projet NutriHFr :

Data

- toutes les sources sont documentées ;
- toutes les transformations sont traçables ;
- les versions sont enregistrées ;
- les unités sont harmonisées.

Qualité

- taux de valeurs manquantes calculé ;
- doublons contrôlés ;
- valeurs aberrantes identifiées ;
- intégrité référentielle vérifiée ;
- couverture du mapping calculée.

Nutrition

- apports calculés ;
- unités vérifiées ;
- nutriments documentés ;
- cas particuliers traités.

Statistiques

- analyses descriptives ;
- comparaison âge/sexe ;
- intervalles de confiance ;
- pondérations d'enquête utilisées ;
- hypothèses statistiques documentées.

Reproductibilité

- code versionné ;
- environnement reproductible ;
- tests automatisés ;
- pipeline relançable ;
- README complet.

Annexe B. Les livrables

Les 7 livrables attendus sont les suivants :

1. README

Explique :

- contexte ;
- problématique ;
- sources ;
- méthodologie ;
- résultats ;
- limites.

2. Data dictionary

Chaque variable est documentée (nom, définition, type, unité, source).

3. Data Quality Report

Avec les contrôles et leurs résultats.

Par exemple, pour le projet NutriHFr, 8 dimensions sont à analyser :

Dimension	Exemple de contrôle
Complétude	% de valeurs manquantes
Unicité	doublons individu/aliment/date
Validité	âge ≥ 0, quantité ≥ 0
Cohérence	date de consommation compatible avec l'enquête
Intégrité référentielle	aliment consommé présent dans Ciqual
Exactitude/plausibilité	quantité alimentaire raisonnable
Homogénéité	unités cohérentes
Traçabilité	origine de chaque valeur calculée (voir Annexe C)

4. Pipeline Python

Reproductible, structuré en classes et relançable de bout en bout.

5. Analyse statistique

Avec graphiques et interprétation.

6. Dashboard

Pour explorer les résultats de façon interactive (par exemple avec Streamlit ou Dash).

7. Rapport final

5–10 pages maximum.

Annexe C. Traçabilité

Chaque résultat doit être accompagné de son lignage (data lineage), c’est-à-dire de l’ensemble des éléments permettant de le reproduire.

Par exemple :

```
Calcium moyen
│
├── Population
│   ├── Sexe = Femme
│   └── Age = 25-44
│
├── Source consommation
│   └── INCA 3
│
├── Composition
│   └── Ciqual 2025
│
├── Mapping
│   └── mapping_v1.2
│
├── Formule
│   └── quantity_g / 100 × value_Ciqual
│
├── Agrégation
│   └── moyenne des jours d’enquête par individu, puis moyenne pondérée
│
├── Pondération
│   └── sampling_weight
│
└── Code
    └── Git commit XXXXX
```

Annexe D. Tests automatisés

Les tests automatisés sont fortement valorisés : ils démontrent la fiabilité du pipeline.

Test 1

```
aucune quantité négative
```

Test 2

```
100 % des nutriments ont une unité connue
```

Test 3

```
Tout food_id consommé a une correspondance dans Ciqual, ou figure dans une
table d'exceptions documentée.
```

Test 4

Pour un aliment connu :

```
100 g × composition Ciqual
```

doit donner le résultat attendu.

Test 5

Une personne avec :

```
0 g consommé
```

doit avoir :

```
0 apport
```

pour les nutriments calculables.

Test 6

La somme des poids d'échantillonnage est cohérente avec la population de référence.

Test 7

L'énergie recalculée à partir des macronutriments (coefficients d'Atwater) est proche de l'énergie indiquée dans Ciqual.